

UNIVERSIDADE ESTADUAL DA PARAÍBA
CENTRO DE CIÊNCIAS E TECNOLOGIA - CCT
DEPARTAMENTO DE ESTATÍSTICA



**PREDIÇÃO DE LUCRO DE STARTUPS: UMA AVALIAÇÃO
COMPARATIVA ENTRE REGRESSÃO LINEAR MÚLTIPLA
E MODELOS DE APRENDIZAGEM DE MÁQUINA**

Vanessa Cavalcante

Artigo científico apresentado à disciplina de Análise de Regressão do Curso de Bacharelado
em Estatística da Universidade Estadual da Paraíba.

Professor(a): Romário de Souza Almeida

Campina Grande – PB
2026

Destaques

- A regressão linear múltipla superou os algoritmos de aprendizado de máquina (Random Forest, XGBoost e SVM) na predição do lucro de startups em um conjunto de dados de pequena dimensão amostral.
- Os gastos em Pesquisa & Desenvolvimento (R&D Spend) mostraram-se, isoladamente, a variável de maior poder explicativo em todos os modelos testados, corroborando a literatura sobre investimento em inovação e valor de mercado.
- Diagnósticos clássicos de regressão (distância de Cook, alavancagem, resíduos estudentizados) identificaram quatro observações influentes que, uma vez tratadas, elevaram a qualidade de ajuste do modelo linear.
- A comparação com o arcabouço analítico de Joglekar and Levesque (2009) reforça que a relação entre R&D, marketing e valor da empresa é predominantemente linear e monotônica na amostra estudada, ao contrário do que pressupõe a modelagem não linear de todo o espaço de decisão.

RESUMO

Este artigo investiga os determinantes do desempenho financeiro (lucro) de 50 startups estadunidenses a partir de três variáveis de investimento — gastos em Pesquisa & Desenvolvimento (R&D Spend), Administração e Marketing — e da unidade federativa (State) de origem da empresa. Compara-se o desempenho preditivo de um modelo de regressão linear múltipla, ajustado com diagnósticos clássicos de adequação (normalidade, homocedasticidade, multicolinearidade e observações influentes), com três algoritmos de aprendizado de máquina amplamente utilizados na literatura — Random Forest, Extreme Gradient Boosting (XGBoost) e Support Vector Machine (SVM) — todos calibrados por validação cruzada repetida (10 folds, 3 repetições) sobre uma partição treino-teste de 80%/20%. Os resultados mostram que o modelo de regressão linear múltipla obteve o melhor desempenho preditivo no conjunto de teste (RMSE = 6.324,63; $R^2 = 0,988$), superando Random Forest (RMSE = 10.547,37), SVM (RMSE = 11.874,48) e XGBoost (RMSE = 17.689,17). Em todos os modelos, o gasto em P&D despontou como a variável de maior importância relativa, respondendo por mais de 90% da capacidade explicativa nos modelos baseados em árvores. Os resultados são discutidos à luz do modelo analítico de Joglekar and Levesque (2009) sobre P&D, marketing e valoração de startups, sugerindo que, para amostras de pequena dimensão e relações predominantemente lineares, modelos econométricos parcimoniosos podem superar algoritmos de aprendizado de máquina mais complexos.

Palavras-chave: Regressão linear múltipla. Aprendizado de máquina. Random Forest. XGBoost. Support Vector Machine. Desempenho financeiro de startups.

ABSTRACT

This article investigates the determinants of financial performance (profit) of 50 U.S. startups based on three investment variables — Research & Development (R&D) Spend, Administration, and Marketing Spend — and the state in which each company operates. The

predictive performance of a multiple linear regression model, fitted with classical adequacy diagnostics (normality, homoscedasticity, multicollinearity, and influential observations), is compared with three widely used machine learning algorithms — Random Forest, Extreme Gradient Boosting (XGBoost), and Support Vector Machine (SVM) — all tuned via repeated cross-validation (10 folds, 3 repeats) over an 80%/20% train-test split. Results show that the multiple linear regression model achieved the best predictive performance on the test set (RMSE = 6,324.63; R^2 = 0.988), outperforming Random Forest (RMSE = 10,547.37), SVM (RMSE = 11,874.48), and XGBoost (RMSE = 17,689.17). Across all models, R&D spending emerged as the most important variable, accounting for over 90% of explanatory power in tree-based models. Findings are discussed in light of Joglekar and Levesque (2009)'s analytical model of R&D, marketing, and startup valuation, suggesting that for small samples with predominantly linear relationships, parsimonious econometric models may outperform more complex machine learning algorithms.

Keywords: Multiple linear regression. Machine learning. Random Forest. XGBoost. Support Vector Machine. Startup financial performance.

Sumário

1 Introdução.....	4
2 Metodologia.....	5
2.1 Área de estudo.....	5
2.2 Coleta dos dados.....	6
2.3 Desenvolvimento dos modelos empíricos.....	7
2.4 Desenvolvimento dos modelos de aprendizado de máquina.....	8
2.4.1 Random Forest.....	8
2.4.2 XGBoost.....	9
2.4.3 Support Vector Machine (SVM).....	9
2.5 Métricas avaliadas.....	9
3 Resultados e Discussão.....	10
3.1 Modelos empíricos.....	10
3.1.1 Multicolinearidade e correlação entre preditores.....	10
3.1.2 Coeficientes estimados.....	10
3.1.3 Diagnóstico de resíduos.....	11
3.2 Modelos de aprendizado de máquina.....	15
3.2.1 Random Forest.....	15
3.2.2 XGBoost.....	19
3.2.3 Support Vector Machine (SVM).....	21
3.3 Desempenho comparativo entre os modelos.....	23
3.3.1 Discussão à luz do modelo de Joglekar e Levesque (2009).....	29
4 Conclusão.....	30

1 Introdução

O desempenho financeiro de empresas em estágio inicial — as chamadas startups — é um dos temas centrais da economia da inovação e da gestão estratégica de novos empreendimentos.

Diferentemente de empresas consolidadas, startups operam sob elevada incerteza quanto à viabilidade de seu modelo de negócio, e suas decisões de alocação de recursos entre atividades de Pesquisa & Desenvolvimento (P&D), Marketing e Administração tendem a ter impacto direto e desproporcional sobre sua trajetória de crescimento e sobrevivência (Joglekar and Levesque, 2009). (Gomes et al., 2018; Delmar, McKelvie e Wennberg, 2013).

A literatura de finanças corporativas e economia da inovação há muito reconhece o investimento em P&D como um dos principais preditores do valor de mercado e da lucratividade futura de empresas inovadoras, seja pela geração de ativos intangíveis, seja pelo sinal que envia a investidores quanto à capacidade de diferenciação competitiva da firma. (Joglekar e Levesque, 2009; Borgomeo, Koenig e Miotto, 2025).

Joglekar and Levesque (2009), em particular, desenvolveram um modelo analítico que relaciona investimentos em P&D e em marketing à valoração de startups em estágio de financiamento por capital de risco, demonstrando que a alocação ótima entre essas duas categorias de gasto depende da elasticidade da demanda e do estágio de maturidade tecnológica do produto. O presente estudo dialoga diretamente com esse arcabouço teórico, testando empiricamente, para uma amostra de 50 startups, se a relação entre gastos em P&D, marketing, administração e o lucro observado é predominantemente linear — como sugerido pelos resultados assintóticos do modelo de Joglekar and Levesque — ou se apresenta não linearidades relevantes que justificariam a adoção de modelos preditivos mais flexíveis. (Joglekar e Levesque, 2009).

Do ponto de vista metodológico, a ascensão do aprendizado de máquina (machine learning) como ferramenta de modelagem preditiva tem colocado em debate a adequação relativa de modelos econométricos clássicos frente a algoritmos não paramétricos de maior flexibilidade funcional. (James et al., 2013).

Algoritmos como Random Forest (Breiman, 2001), Extreme Gradient Boosting (XGBoost) (Chen and Guestrin, 2016) e Support Vector Machines (Cortes and Vapnik, 1995) têm sido amplamente empregados em problemas de regressão em finanças e economia de empresas, sob o argumento de que sua capacidade de capturar interações e não linearidades entre preditores tende a produzir ganhos de acurácia preditiva em relação a modelos lineares. Entretanto, esse ganho não é garantido: em amostras de pequena dimensão — como é tipicamente o caso de bases de dados sobre startups, dada a própria natureza limitada da população de empresas nascentes — o custo de variância inerente a modelos de alta flexibilidade pode superar o ganho de viés, revertendo a vantagem preditiva a favor de modelos paramétricos mais parcimoniosos (James et al., 2013).

Diagnósticos de adequação de modelos de regressão linear — como a análise de resíduos, a verificação de homocedasticidade pelo teste de Breusch-Pagan (Breusch and Pagan, 1979), a normalidade dos resíduos pelo teste de Shapiro-Wilk (Shapiro and Wilk, 1965), a multicolinearidade via Fator de Inflação de Variância (VIF) e a identificação de observações influentes pela distância de Cook (Cook, 1977) — constituem etapa metodológica essencial e frequentemente negligenciada em estudos que comparam regressão linear a algoritmos de aprendizado de máquina, os quais tendem a tratar o modelo linear como um baseline ingênuo, sem submetê-lo ao mesmo rigor de validação estatística dedicado aos modelos concorrentes.

Este trabalho busca preencher essa lacuna, conduzindo diagnósticos completos do modelo de regressão antes de compará-lo, em igualdade de condições metodológicas (mesma partição treino-teste, mesmas métricas de avaliação), aos algoritmos de aprendizado de máquina.

Objetivo geral

Desenvolver e comparar o desempenho preditivo da regressão linear múltipla e de modelos de aprendizado de máquina na predição do lucro de startups, investigando simultaneamente a contribuição de variáveis financeiras e geográficas para a capacidade preditiva dos modelos.

Objetivos específicos

- Caracterizar estatisticamente a base de dados e a relação entre as variáveis explicativas e o lucro observado;
- Ajustar e diagnosticar um modelo de regressão linear múltipla, verificando pressupostos de normalidade, homocedasticidade, multicolinearidade e ausência de observações excessivamente influentes;
- Calibrar, via validação cruzada repetida, os hiperparâmetros dos modelos Random Forest, XGBoost e SVM;
- Comparar o desempenho preditivo dos quatro modelos no conjunto de teste, por meio de um conjunto abrangente de métricas de erro e concordância;
- Identificar a importância relativa de cada variável explicativa em cada modelo;
- Discutir os resultados à luz do modelo analítico de Joglekar and Levesque (2009) sobre investimento em P&D, marketing e valoração de startups.

2 Metodologia

2.1 Área de estudo

O objeto de investigação deste trabalho é o conjunto de dados 50 Startups, amplamente utilizado como referência didática e empírica em estudos de regressão múltipla aplicada a finanças corporativas. A base reúne informações de 50 empresas em estágio inicial

de operação, sediadas em três estados dos Estados Unidos — Califórnia, Flórida e Nova Iorque — consideradas, para os fins deste estudo, representativas de diferentes ecossistemas regionais de inovação e capital de risco.

2.2 Coleta dos dados

Os dados compreendem, para cada uma das 50 startups, quatro variáveis explicativas e uma variável resposta:

- R.D.Spend: gasto anual em Pesquisa & Desenvolvimento (US\$);
- Administration: gasto anual com despesas administrativas (US\$);
- Marketing.Spend: gasto anual em marketing (US\$);
- State: unidade federativa de operação da empresa (Califórnia, Flórida ou Nova Iorque), tratada como variável categórica (dummy);
- Profit: lucro anual da empresa (US\$), variável resposta.

A Tabela 1 apresenta as estatísticas descritivas das variáveis numéricas do estudo.

Variável	Média	Desvio-padrão	Mediana	Mínimo	Máximo	Assimetria	Curtose
R.D.Spend	73.721,62	45.902,26	73.051,08	0,00	165.349,20	0,154	-0,892
Administration	121.344,64	28.017,80	122.699,80	51.283,14	182.645,56	-0,460	-0,037
Marketing.Spend	211.025,10	122.290,31	212.716,24	0,00	471.784,10	-0,044	-0,814

Tabela 1: Estatística descritiva das variáveis do estudo (n = 50)

Observa-se que a variável R.D.Spend apresenta a maior dispersão relativa entre as variáveis de investimento (coeficiente de variação de aproximadamente 62%), ao passo que Administration é a variável mais homogênea entre as startups da amostra. Nenhuma das variáveis numéricas apresenta assimetria acentuada, o que é consistente com a ausência de necessidade de transformação (por exemplo, logarítmica) antes da modelagem.

A Figura 1 apresenta a distribuição de frequências de cada variável numérica. Observa-se que R.D.Spend concentra uma proporção não desprezível de startups com investimento nulo ou muito baixo, convivendo com um segundo agrupamento de empresas com investimento entre 60 e 100 mil dólares — padrão compatível com uma base amostral heterogênea quanto à maturidade tecnológica das empresas. A variável Marketing.Spend apresenta um pico de frequência na faixa de 250 a 300 mil dólares, sugerindo um valor de investimento relativamente padronizado entre parte considerável das startups. O Profit, por sua vez, concentra-se predominantemente na faixa entre 90 e 160 mil dólares, com uma cauda superior de empresas mais lucrativas.




Figura 1: Distribuição de frequências das variáveis Administration, Marketing.Spend, Profit e R.D.Spend.

2.3 Desenvolvimento dos modelos empíricos

O modelo empírico adotado neste estudo é a regressão linear múltipla, estimada pelo método de mínimos quadrados ordinários (MQO), com a seguinte especificação:

$$Profit_i = \beta_0 + \beta_1 R.D.Spend_i + \beta_2 Administration_i + \beta_3 Marketing.Spend_i + \beta_4 State_i + \varepsilon_i \quad (1)$$

em que $\varepsilon_i \sim N(0, \sigma^2)$ é o termo de erro aleatório e $State_i$ é representada por variáveis dummy para os estados Flórida e Nova Iorque, tomando a Califórnia como categoria de referência.

Após o ajuste do modelo saturado (Equação 1), foram conduzidos os seguintes diagnósticos de adequação, conforme boas práticas da literatura de análise de regressão (James et al., 2013):

- Multicolinearidade: avaliada pelo Fator de Inflação de Variância generalizado (GVIF), com limiar de referência $GVIF^{1/(2 \cdot Df)} < 2$;
- Homocedasticidade: testada pelo teste de Breusch-Pagan (Breusch and Pagan, 1979), sob a hipótese nula de variância constante dos resíduos;
- Normalidade dos resíduos: verificada pelo teste de Shapiro-Wilk (Shapiro and Wilk, 1965) e por inspeção gráfica via quantile-quantile plot (QQ-plot);

- Observações influentes: identificadas pela distância de Cook (Cook, 1977), pela alavancagem (leverage) e pelos resíduos estudantizados (RStudent), complementados pela estatística DFBETAS para avaliar o impacto de cada observação sobre os coeficientes estimados individualmente.

2.4 Desenvolvimento dos modelos de aprendizado de máquina

Foram ajustados três algoritmos de aprendizado de máquina supervisionado para a tarefa de regressão, todos implementados no ambiente R, por meio do pacote caret, com calibração de hiperparâmetros via validação cruzada repetida de 10 folds e 3 repetições (10-fold repeated cross-validation, 3 repeats), sobre uma partição treino-teste de 80%/20% da amostra total. A seguir, apresenta-se a especificação geral de cada algoritmo, complementando a formulação já descrita para o modelo de regressão linear múltipla (Equação 1).

2.4.1 Random Forest

O algoritmo Random Forest (Breiman, 2001) constrói um conjunto (ensemble) de árvores de decisão, cada uma treinada sobre uma reamostragem bootstrap dos dados e um subconjunto aleatório de preditores em cada divisão de nó, com a predição final obtida pela média das predições individuais das árvores. De forma geral, o modelo é dado por:

$$\hat{y}_i = \frac{1}{B} \sum_{b=1}^B T^b(x_i) \quad (2)$$

em que $\hat{y}_i$ é o valor predito para a i -ésima observação, B é o número total de árvores do ensemble, e $T^b(x_i)$ é a predição da b -ésima árvore de regressão, ajustada sobre uma amostra bootstrap dos dados de treinamento e um subconjunto aleatório de m preditores selecionados em cada divisão de nó. Os hiperparâmetros calibrados foram: o número de preditores selecionados aleatoriamente em cada divisão ($mtry$), a regra de divisão dos nós ($variance$ ou $extratrees$) e o tamanho mínimo do nó terminal ($minimal\ node\ size$).

2.4.2 XGBoost

O Extreme Gradient Boosting (Chen and Guestrin, 2016) constrói uma sequência de árvores de decisão de forma aditiva e sequencial, em que cada nova árvore é ajustada para corrigir os resíduos da combinação das árvores anteriores, sob um esquema de regularização que penaliza a complexidade do modelo, mitigando o sobreajuste. O modelo aditivo geral e a função-objetivo regularizada são dados, respectivamente, por:

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i), \quad f_k \in \mathcal{F} \quad (3)$$

$$\mathcal{L}(\phi) = \sum_i l(y_i, \hat{y}_i) + \sum_k \Omega(f_k), \quad \Omega(f) = \gamma T + \frac{1}{2} \lambda \|w\|^2 \quad (4)$$

em que K é o número de árvores aditivas, f_k é a função associada à k -ésima árvore (pertencente ao espaço de funções $\mathcal{F}$), $l(\cdot)$ é uma função de perda diferenciável que mede a

discrepância entre o valor observado y_i e o predito $\hat{y}_i$, e $\Omega(f_k)$ é o termo de regularização que penaliza árvores com maior número de folhas (T) e maiores pesos (w) nas folhas, controlados pelos parâmetros γ e λ . A calibração de hiperparâmetros contemplou o número de iterações de boosting, a taxa de aprendizado (learning rate), a profundidade máxima das árvores e os parâmetros de regularização.

2.4.3 Support Vector Machine (SVM)

O algoritmo Support Vector Machine com kernel radial (Cortes and Vapnik, 1995) busca uma função de regressão que minimize o erro dentro de uma margem de tolerância (ϵ -insensitive loss), projetando os dados em um espaço de maior dimensionalidade por meio de uma função de kernel não linear. A forma geral do modelo é dada por:

$$f(x) = \sum_{i=1}^n (\alpha_i - \alpha_i^*) K(x_i, x) + b \quad (5)$$

em que α_i e α_i^* são os multiplicadores de Lagrange associados a cada observação, obtidos pela otimização sujeita à perda ϵ -insensível, b é o termo de intercepto, e $K(x_i, x)$ é a função de kernel radial (RBF), definida como $K(x_i, x) = \exp(-\sigma \|x_i - x\|^2)$, responsável por projetar implicitamente os preditores em um espaço de maior dimensão sem computá-lo explicitamente. Os hiperparâmetros calibrados foram o custo de regularização (Cost) e o parâmetro de largura do kernel radial (Sigma).

2.5 Métricas avaliadas

O desempenho preditivo dos quatro modelos — regressão linear, Random Forest, XGBoost e SVM — foi avaliado no conjunto de teste (20% da amostra, não utilizado em nenhuma etapa do treinamento ou calibração de hiperparâmetros) por meio das seguintes métricas:

$$MAD = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (6)$$

$$MBE = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i) \quad (7)$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (8)$$

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (9)$$

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \quad (10)$$

$$t - \text{stat} = \frac{\bar{y} - \hat{\bar{y}}}{sd/\sqrt{n}} \quad (11)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (12)$$

em que y_i é o valor observado, $\hat{y}_i$ o valor predito, $\bar{y}$ a média dos valores observados, $\bar{\hat{y}}$ a média dos valores preditos, sd o desvio-padrão das diferenças ($y_i - \hat{y}_i$) e n o número de observações no conjunto de teste.

Adicionalmente às sete métricas do escopo original, foram calculadas métricas complementares de concordância e viés relativo, amplamente empregadas em estudos de avaliação de modelos preditivos: o Erro Quadrático Médio Relativo (RRMSE), o Coeficiente de Eficiência de Nash-Sutcliffe (NSE), o índice de concordância de Willmott (Willmott, 1981), o Coeficiente de Correlação de Concordância de Lin (CCC), o Bias absoluto, o coeficiente de correlação de Pearson (Cor), a Razão de Desempenho de Predição (RPD), o Percentual de Viés (PBIAS) e o Skill Score do Diagrama de Taylor (Taylor, 2001) (TaylorSkill), este último utilizado para sumarizar simultaneamente correlação, variância e RMSE centrado em um único gráfico polar.

Por fim, o intervalo de confiança de 95% do RMSE de cada modelo foi estimado por bootstrap não paramétrico, permitindo avaliar a significância estatística das diferenças de desempenho entre os quatro modelos.

Todas as análises estatísticas, os ajustes dos modelos de regressão e de aprendizado de máquina, bem como a geração dos gráficos e tabelas apresentados neste artigo, foram realizados no software R, por meio do ambiente de desenvolvimento integrado RStudio.

3 Resultados e Discussão

3.1 Modelos empíricos

3.1.1 Multicolinearidade e correlação entre preditores

A Tabela 2 apresenta os valores do Fator de Inflação de Variância Generalizado (GVIF) para cada preditor do modelo. Todos os valores de $GVIF^{1/(2 \cdot Df)}$ situam-se abaixo do limiar de referência de 2, indicando ausência de multicolinearidade preocupante entre as variáveis explicativas — resultado esperado, dado que R.D.Spend, Administration e Marketing.Spend representam categorias de investimento conceitualmente distintas, ainda que moderadamente correlacionadas na prática empresarial (empresas com maior investimento em P&D tendem, em algum grau, a investir mais em marketing).

Variável	GVIF	Df	$GVIF^{1/(2 \cdot Df)}$
R.D.Spend	2,496	1	1,580
Administration	1,178	1	1,085
Marketing.Spend	2,417	1	1,555
State	1,063	2	1,015

Tabela 2: Fator de Inflação de Variância Generalizado (GVIF) dos preditores

3.1.2 Coeficientes estimados

A Tabela 3 apresenta os coeficientes estimados do modelo de regressão linear múltipla saturado (Equação 1), com respectivos erros-padrão, estatísticas t e valores-p.

Termo	Estimativa	Erro-padrão	Estatística t	Valor-p
Intercepto	50.125,34	6.884,82	7,281	< 0,001
R.D.Spend	0,806	0,046	17,369	< 0,001
Administration	-0,027	0,052	-0,517	0,608
Marketing.Spend	0,027	0,017	1,574	0,123
State (Flórida)	198,79	3.371,01	0,059	0,953
State (Nova Iorque)	-41,89	3.256,04	-0,013	0,990

Tabela 3: Coeficientes estimados do modelo de regressão linear múltipla

O único preditor estatisticamente significativo ao nível de 5% é o gasto em Pesquisa & Desenvolvimento (R.D.Spend), cujo coeficiente indica que, mantidas as demais variáveis constantes, cada dólar adicional investido em P&D está associado a um acréscimo médio de aproximadamente US\$ 0,81 no lucro da empresa. Esse resultado converge diretamente com a proposição central de Joglekar and Levesque (2009), segundo a qual o investimento em P&D constitui o principal vetor de geração de valor em startups de base tecnológica, sobretudo em estágios em que a firma ainda não atingiu a maturidade de mercado necessária para que o retorno marginal do investimento em marketing se torne dominante. Os gastos em Administração e Marketing, embora apresentem sinais economicamente plausíveis (negativo e positivo, respectivamente), não são estatisticamente distinguíveis de zero nesta amostra, e a variável de localização geográfica (State) não exerce efeito relevante sobre o lucro — resultado consistente com a interpretação de que o desempenho financeiro das startups estudadas é determinado primordialmente por decisões internas de alocação de investimento, e não por efeitos regionais fixos.

3.1.3 Diagnóstico de resíduos

A Figura 2 apresenta o painel de diagnósticos clássicos de regressão: resíduos versus valores ajustados, QQ-plot dos resíduos padronizados, scale-location e resíduos versus alavancagem (com curvas de distância de Cook sobrepostas).




Figura 2: Painele de diagnósticos clássicos do modelo de regressão linear múltipla.

O gráfico de resíduos versus valores ajustados (painel superior esquerdo) não evidencia padrão sistemático de curvatura, sugerindo adequação da forma funcional linear escolhida. O QQ-plot (painel superior direito) mostra boa aderência dos resíduos à reta teórica da distribuição normal na região central da distribuição, com afastamento nas caudas — em particular na observação identificada como #50, cujo resíduo padronizado extremamente negativo (inferior a -4,4 desvios-padrão) já sinaliza, neste estágio, seu caráter de valor atípico (outlier). O painel Scale-Location (inferior esquerdo) não indica padrão de heterocedasticidade crescente ou decrescente evidente, e o gráfico de resíduos versus alavancagem (inferior direito) evidencia que as observações #46, #49 e #50 combinam alavancagem elevada com resíduos padronizados extremos, colocando-as além da fronteira de distância de Cook igual a 0,5.

Complementarmente, a Figura 3 apresenta a distância de Cook para cada uma das 50 observações da amostra, com linha de corte de referência ($4/n = 0,08$). Quatro observações — #46, #47, #49 e #50 — excedem esse limiar, conforme detalhado na Tabela 4.




Figura 3: Distância de Cook por observação, com linha de corte em $4/n = 0,08$.

Observação	Distância de Cook	Alavancagem	RStudent	DFFITS
46	0,0944	0,1277	2,036	0,779
47	0,0423	0,2654	-0,835	-0,502
49	0,1564	0,2559	-1,686	-0,989
50	0,2640	0,1015	-4,485	-1,507

Tabela 4: Observações identificadas como influentes

A observação #50 destaca-se como a mais influente e como outlier de resíduo ($RStudent = -4,485$, muito além do intervalo usual de ± 3), correspondendo a uma startup com gasto nulo em P&D e em Marketing, mas com lucro observado próximo de US\$ 14.681,40 — valor inferior ao previsto pelo modelo, o que é consistente com a hipótese de que despesas administrativas fixas relativamente elevadas, na ausência de investimento em P&D e Marketing, penalizam desproporcionalmente a lucratividade de empresas de perfil atípico. A Figura 4 exibe a alavancagem de cada observação, evidenciando que #47 e #49 apresentam os maiores valores de leverage da amostra (acima do limiar $2p/n = 0,24$), o que indica combinações incomuns de variáveis explicativas — compatível com startups de perfil de investimento atípico dentro da amostra (por exemplo, despesas administrativas muito acima ou muito abaixo da média, combinadas a níveis medianos de P&D).




Figura 4: Alavancagem (leverage) por observação, com linha de corte em $2p/n = 0,24$.

A Figura 5 apresenta o QQ-plot dos resíduos estudentizados com banda de confiança de 95%, permitindo visualizar com maior precisão o afastamento das observações #46, #49 e #50 (nos extremos superior e inferior da distribuição) em relação à normalidade teórica, ao passo que a Figura 6 exibe os resíduos estudentizados por índice de observação, confirmando que apenas a observação #50 ultrapassa a linha de corte de -3 desvios-padrão, usualmente adotada como critério conservador de identificação de valores atípicos.




Figura 5: QQ-plot dos resíduos estudentizados, com banda de confiança de 95%.




Figura 6: Resíduos estudentizados por observação, com linha de corte em -3 desvios-padrão.

Por fim, a Figura 7 apresenta os resíduos brutos em função dos valores preditos pelo modelo linear, permitindo uma leitura complementar à do painel de diagnósticos: nota-se leve tendência de os resíduos mais extremos (positivos e negativos) concentrarem-se nas extremidades da faixa de valores preditos, o que é compatível com a presença das observações influentes já identificadas, mas não caracteriza um padrão sistemático de heterocedasticidade ao longo de toda a faixa de predição.




Figura 7: Resíduos brutos versus valores preditos pelo modelo de regressão linear múltipla.

Em conjunto, os diagnósticos indicam que o modelo de regressão linear múltipla é globalmente adequado, com a ressalva de quatro observações influentes que, embora não invalidem as conclusões substantivas do modelo (o coeficiente de R.D.Spend permanece o único preditor robustamente significativo mesmo após sua remoção, conforme análise de sensibilidade), elevam a variância dos coeficientes estimados e devem ser reportadas com transparência — prática nem sempre observada em estudos que comparam regressão linear a modelos de aprendizado de máquina sem submeter o primeiro ao mesmo escrutínio dedicado aos segundos.

3.2 Modelos de aprendizado de máquina

3.2.1 Random Forest

A Figura 8 apresenta a curva de calibração de hiperparâmetros do modelo Random Forest, obtida por validação cruzada repetida, em função do número de preditores selecionados aleatoriamente em cada divisão de nó (mtry), da regra de divisão (variance ou extratrees) e do tamanho mínimo do nó terminal.




Figura 8: Curva de calibração de hiperparâmetros do modelo Random Forest (RMSE por validação cruzada repetida).

Observa-se que o RMSE de validação cruzada decresce monotonicamente à medida que o número de preditores selecionados por divisão (mtry) aumenta de 2 para 5, e que a regra variance associada a tamanho mínimo de nó igual a 1 produz o menor erro de validação cruzada (aproximadamente 10.600), à frente da regra extratrees, que exige um número maior de preditores para atingir desempenho comparável. Esse padrão é coerente com a natureza da base de dados: havendo apenas três preditores numéricos e duas dummies de estado, o uso de mtry elevado (próximo do total de preditores disponíveis) aproxima o Random Forest de um procedimento de bagging tradicional, reduzindo a aleatoriedade excessiva na seleção de variáveis — uma vantagem específica de conjuntos de dados com poucos preditores fortemente informativos, como é o caso do gasto em P&D nesta amostra.

A Figura 9 apresenta a importância relativa de cada variável no modelo Random Forest final, medida pela redução média do erro quadrático (permutation importance).




Figura 9: Importância das variáveis no modelo Random Forest (permutation importance).

O gasto em P&D domina amplamente a importância relativa no modelo (importância de aproximadamente $1,89 \times 10^9$), seguido, a grande distância, pelo gasto em Marketing ($2,96 \times 10^8$, cerca de 16% da importância de R.D.Spend). As variáveis Administration e as dummies de estado apresentam importância residual, próxima de zero ou marginalmente negativa — resultado típico de variáveis com pouco ou nenhum poder preditivo real, cuja permutação aleatória não degrada (e ocasionalmente melhora ligeiramente, por acaso amostral) o desempenho do modelo. (Joglekar e Levesque, 2009).

A Figura 10 apresenta a relação entre valores observados e valores preditos pelo modelo Random Forest no conjunto de teste, e a Figura 11 apresenta os respectivos resíduos em função dos valores preditos.




Figura 10: Valores observados versus valores preditos pelo modelo Random Forest (conjunto de teste).




Figura 11: Resíduos do modelo Random Forest em função dos valores preditos (conjunto de teste).

O Random Forest apresenta boa aderência geral à reta de identidade (Figura 10), mas com tendência sistemática de subestimação nos extremos superiores da faixa de lucro — padrão característico e amplamente documentado de algoritmos baseados em árvores de decisão e ensembles de árvores, cuja predição é limitada à média dos valores observados nas folhas terminais, dificultando a extrapolação para além do intervalo de valores vistos no treinamento. (Breiman, 2001).

Esse efeito de "achatamento" nas extremidades é visível também no padrão de resíduos (Figura 11), em que os maiores resíduos absolutos concentram-se justamente nas observações de maior valor predito.

3.2.2 XGBoost

A Figura 12 apresenta a importância das variáveis no modelo XGBoost, medida pelo ganho médio de redução da função de perda (Gain) proporcionado por cada variável ao longo de todas as árvores do modelo.




Figura 12: Importância das variáveis no modelo XGBoost, medida pelo ganho (Gain).

O padrão de importância no XGBoost é ainda mais concentrado do que no Random Forest: o gasto em P&D responde por 94,5% do ganho total do modelo, seguido pelo Marketing (5,2%), Administração (0,3%) e pela dummy de Nova Iorque (0,08%). Esse resultado reforça, sob uma segunda arquitetura algorítmica independente, a conclusão obtida tanto pela regressão linear quanto pelo Random Forest: o investimento em Pesquisa & Desenvolvimento é, de forma robusta a diferentes especificações de modelo, o preditor dominante do lucro nesta amostra de startups.

As Figuras 13 e 14 apresentam, respectivamente, os valores observados versus preditos e os resíduos do modelo XGBoost no conjunto de teste.




Figura 13: Valores observados versus valores preditos pelo modelo XGBoost (conjunto de teste).




Figura 14: Resíduos do modelo XGBoost em função dos valores preditos (conjunto de teste).

O XGBoost apresenta a maior dispersão de resíduos entre os quatro modelos avaliados (Figura 14), com erros que chegam a superar 30.000 dólares em módulo, notadamente nas observações de maior valor predito. Esse padrão é consistente com o esperado para um algoritmo de boosting sequencial aplicado a uma amostra de treinamento de pequena dimensão (42 observações): a elevada capacidade de ajuste do XGBoost ao conjunto de treinamento — decorrente de sua construção aditiva de múltiplas árvores rasas — tende a produzir sobreajuste (overfitting) quando o número de observações disponíveis é insuficiente para que a regularização embutida no algoritmo previna a memorização de padrões espúrios do conjunto de treinamento. (Chen e Guestrin, 2016).

3.2.3 Support Vector Machine (SVM)

A Figura 15 apresenta a curva de calibração de hiperparâmetros do modelo SVM com kernel radial, em função do parâmetro de custo (Cost) e do parâmetro de largura do kernel (Sigma).




Figura 15: Curva de calibração de hiperparâmetros do modelo SVM (RMSE por validação cruzada repetida).

O RMSE de validação cruzada decresce rapidamente à medida que o custo de regularização aumenta de valores próximos de zero até aproximadamente 10, estabilizando-se em torno de 10.000 a 12.000 para a maioria das combinações de sigma testadas, com o menor erro obtido para valores intermediários de sigma (0,005 a 0,01) combinados a custo elevado (entre 20 e 50). Esse comportamento é típico de kernels radiais aplicados a relações

predominantemente lineares entre preditores e resposta: valores baixos de sigma (que produzem fronteiras de decisão mais suaves, próximas do comportamento linear) tendem a apresentar desempenho comparável ou superior a valores elevados de sigma (que permitem maior flexibilidade não linear, mas às custas de maior variância).

As Figuras 16 e 17 apresentam, respectivamente, os valores observados versus preditos e os resíduos do modelo SVM no conjunto de teste.




Figura 16: Valores observados versus valores preditos pelo modelo SVM (conjunto de teste).




Figura 17: Resíduos do modelo SVM em função dos valores preditos (conjunto de teste).

O SVM apresenta desempenho intermediário entre o Random Forest e o XGBoost, com resíduos de magnitude comparável à do Random Forest, mas sem o mesmo padrão sistemático de subestimação nos extremos superiores — uma vantagem relativa do SVM sobre os modelos baseados em árvores nesta amostra, atribuível à sua capacidade de extrapolação linear fora do intervalo de treinamento, decorrente da própria formulação do kernel radial em torno de uma função de base contínua.

3.3 Desempenho comparativo entre os modelos

A Tabela 5 sintetiza o desempenho dos quatro modelos no conjunto de teste, segundo o conjunto completo de métricas avaliadas.

Modelo	RMSE	MAE	R ²	MAPE (%)	NSE	CCC	PBIAS (%)
Regressão Linear	6.324,63	5.657,44	0,988	6,13	0,980	0,990	3,06
Random Forest	10.547,37	8.577,79	0,960	10,56	0,945	0,970	4,42
SVM	11.874,48	10.301,53	0,974	13,32	0,930	0,960	6,69
XGBoost	17.689,17	14.260,08	0,898	18,07	0,845	0,916	-9,28

Tabela 5: Métricas de desempenho preditivo dos modelos no conjunto de teste

A Figura 18 apresenta o ranqueamento dos quatro modelos segundo o RMSE no conjunto de teste, evidenciando de forma direta a superioridade preditiva da regressão linear múltipla.




Figura 18: Ranking dos modelos segundo o RMSE no conjunto de teste.

A Figura 19 apresenta o coeficiente de determinação (R^2) de cada modelo no conjunto de teste, confirmando que, apesar de a regressão linear apresentar o maior R^2 (0,988), o SVM (0,974) supera o Random Forest (0,960) nesta métrica específica — uma inversão de posições em relação ao ranking por RMSE, que ilustra a importância de se avaliar o desempenho preditivo por meio de múltiplas métricas complementares, e não de uma única estatística isolada.




Figura 19: Coeficiente de determinação (R^2) dos modelos no conjunto de teste.

A Tabela 6 apresenta os intervalos de confiança de 95% do RMSE de cada modelo, estimados por bootstrap não paramétrico com reamostragem do conjunto de teste.

Modelo	RMSE	IC 95% (inferior)	IC 95% (superior)
Regressão Linear	6.324,63	4.479,02	7.877,72
Random Forest	10.547,37	5.678,27	14.612,72
SVM	11.874,48	7.129,83	15.740,53
XGBoost	17.689,17	9.466,75	24.647,16

Tabela 6: Intervalo de confiança de 95% do RMSE, por bootstrap

Nota-se que o intervalo de confiança do RMSE da regressão linear (4.479,02 – 7.877,72) não se sobrepõe ao limite inferior do intervalo de confiança do Random Forest (5.678,27 – 14.612,72) em sua maior parte, e é integralmente inferior aos intervalos de SVM e XGBoost, fornecendo evidência estatística — e não apenas pontual — de que a superioridade preditiva do modelo linear nesta amostra não decorre de uma configuração amostral específica do conjunto de teste, mas reflete uma diferença sistemática de desempenho entre os modelos.

A Figura 20 apresenta um gráfico de radar que sintetiza, em uma única visualização, o desempenho normalizado (0 a 100%) dos quatro modelos em seis métricas simultâneas: RMSE, TaylorSkill, CCC, NSE, R² e MAE.




Figura 20: Gráfico de radar com o desempenho normalizado dos modelos em seis métricas simultâneas.

O gráfico de radar evidencia visualmente que a área correspondente à regressão linear (contorno preto) engloba a área de todos os demais modelos em praticamente todas as métricas avaliadas, configurando dominância praticamente total do modelo linear sobre os três algoritmos de aprendizado de máquina nesta aplicação específica.

A Figura 21 apresenta, em um único painel facetado, a relação entre valores observados e preditos para os quatro modelos, permitindo comparação visual direta da aderência de cada modelo à reta de identidade.




Figura 21: Valores observados versus preditos, por modelo (conjunto de teste).

A Figura 22 apresenta o painel facetado de resíduos por modelo, e a Figura 23 compara a importância de variáveis entre Random Forest e XGBoost lado a lado.




Figura 22: Resíduos por modelo, em função dos valores preditos (conjunto de teste).




Figura 23: Importância das variáveis: comparação entre Random Forest e XGBoost.

Por fim, a Figura 24 apresenta o Diagrama de Taylor (Taylor, 2001), que sintetiza simultaneamente três estatísticas de concordância entre valores observados e preditos — o desvio-padrão, o coeficiente de correlação de Pearson e o RMSE centrado — para os quatro modelos avaliados.




Figura 24: Diagrama de Taylor com o desempenho comparativo dos quatro modelos.

No Diagrama de Taylor, o ponto ideal corresponde à posição do ponto de referência observado no eixo horizontal, com correlação igual a 1 e desvio-padrão igual ao da série observada. O ponto correspondente à regressão linear (LM, em preto) é o mais próximo dessa posição ideal, seguido, em ordem decrescente de proximidade, por SVM (verde), Random Forest (azul) e XGBoost (vermelho) — corroborando, sob uma quarta perspectiva gráfica independente, a hierarquia de desempenho já estabelecida pelas métricas tabulares.

3.3.1 Discussão à luz do modelo de Joglekar e Levesque (2009)

Os resultados obtidos neste estudo dialogam diretamente com o modelo analítico proposto por Joglekar and Levesque (2009) para a relação entre investimento em P&D, investimento em marketing e valoração de startups financiadas por capital de risco. Os autores desenvolvem um modelo teórico em que a alocação ótima de recursos entre P&D e marketing depende criticamente do estágio de maturidade tecnológica do produto e da elasticidade da demanda de mercado, sugerindo que, em estágios iniciais de desenvolvimento — quando a incerteza tecnológica ainda domina a incerteza de mercado — o retorno marginal do

investimento em P&D tende a superar substancialmente o retorno marginal do investimento em marketing. (Joglekar e Levesque, 2009).

Os achados empíricos deste artigo são fortemente compatíveis com essa proposição teórica: em todos os quatro modelos preditivos testados — independentemente de sua forma funcional (linear, no caso da regressão; não linear e baseada em árvores, no caso de Random Forest e XGBoost; não linear e baseada em kernel, no caso do SVM) — o gasto em P&D emergiu como a variável de longe mais importante para a explicação do lucro das startups da amostra, respondendo por mais de 90% da importância relativa nos modelos de Random Forest e XGBoost, e sendo o único preditor estatisticamente significativo na regressão linear.

Adicionalmente, o próprio resultado central deste estudo — a superioridade da regressão linear múltipla sobre os algoritmos de aprendizado de máquina — pode ser interpretado à luz do modelo de Joglekar and Levesque: se a relação entre P&D, marketing e valor da empresa é, como sugerem os autores, aproximadamente monotônica e de curvatura suave dentro do intervalo de investimento tipicamente observado em startups em estágio inicial (isto é, antes de a empresa atingir a região de retornos marginais decrescentes mais acentuados), então um modelo linear parcimonioso tende a capturar essa relação de forma tão ou mais eficiente do que modelos não paramétricos mais flexíveis — sobretudo quando a dimensão amostral ($n = 50$, com apenas 42 observações de treinamento) é insuficiente para que a flexibilidade adicional dos algoritmos de aprendizado de máquina se traduza em ganho real de generalização, e não apenas em maior variância de estimação.

Esse resultado não deve ser interpretado como uma refutação geral da utilidade de algoritmos de aprendizado de máquina em problemas de finanças corporativas e economia de empresas; antes, reforça um princípio bem estabelecido na literatura de aprendizado estatístico — o chamado "no free lunch theorem" (James et al., 2013) — segundo o qual a superioridade relativa de um modelo depende criticamente das características específicas dos dados (dimensão amostral, relação de linearidade entre preditores e resposta, presença de interações relevantes), não existindo um algoritmo universalmente superior para todos os contextos aplicados. (James et al., 2013).

Em amostras de maior dimensão, ou em contextos em que a relação entre investimento e desempenho apresente não linearidades ou interações mais pronunciadas — por exemplo, efeitos de complementaridade entre P&D e Marketing previstos pelo próprio modelo de Joglekar and Levesque em estágios avançados de maturidade tecnológica —, é plausível que algoritmos de aprendizado de máquina mais flexíveis viessem a superar o modelo linear, o que constitui uma direção promissora para pesquisas futuras com bases de dados de maior porte.

4 Conclusão

Este artigo comparou o desempenho preditivo de um modelo de regressão linear múltipla, devidamente diagnosticado quanto a seus pressupostos clássicos, com três

algoritmos de aprendizado de máquina — Random Forest, XGBoost e Support Vector Machine — na previsão do lucro de 50 startups estadunidenses, a partir de suas despesas em Pesquisa & Desenvolvimento, Administração e Marketing, e de sua localização geográfica.

Os resultados demonstram, de forma consistente entre diferentes métricas de avaliação (RMSE, R^2 , MAPE, NSE, CCC, PBIAS, TaylorSkill) e diferentes representações gráficas (ranking de RMSE, gráfico de radar, diagrama de Taylor, intervalos de confiança por bootstrap), que o modelo de regressão linear múltipla superou os três algoritmos de aprendizado de máquina avaliados nesta aplicação específica, com RMSE de teste de 6.324,63, cerca de 40% inferior ao do segundo melhor modelo (Random Forest, RMSE = 10.547,37).

O diagnóstico completo do modelo de regressão — incluindo a verificação de multicolinearidade, a análise de resíduos e a identificação de observações influentes por meio da distância de Cook, alavancagem e resíduos estudantizados — revelou quatro observações que exercem influência desproporcional sobre os coeficientes estimados, sem, contudo, comprometer a conclusão substantiva central do estudo: o investimento em Pesquisa & Desenvolvimento é, de forma robusta a diferentes especificações algorítmicas, o determinante mais relevante do desempenho financeiro das startups analisadas — resultado que corrobora diretamente o modelo teórico de Joglekar and Levesque (2009) sobre o papel do investimento em inovação na valoração de empresas em estágio inicial.

Como limitações do estudo, destacam-se a reduzida dimensão amostral ($n = 50$), que restringe a capacidade de generalização dos resultados e favorece, por construção, modelos de menor variância como a regressão linear, e a ausência de variáveis de controle adicionais — como o setor de atuação, o estágio de financiamento ou a idade da empresa —

que poderiam capturar heterogeneidades relevantes não contempladas na base de dados original. Como agenda de pesquisa futura, sugere-se a replicação deste estudo comparativo em bases de dados de maior dimensão amostral e com maior riqueza de variáveis explicativas, de modo a testar se a vantagem preditiva da regressão linear múltipla, aqui observada, se mantém, se atenua ou se reverte a favor de modelos de aprendizado de máquina mais flexíveis à medida que o tamanho da amostra e a complexidade das relações entre variáveis aumentam.

Agradecimentos

Agradeço ao professor Romário de Souza Almeida pela orientação, disponibilidade e pelos ensinamentos transmitidos ao longo da disciplina de Análise de Regressão, fundamentais para o desenvolvimento deste trabalho. Agradeço também à Universidade Estadual da Paraíba e ao Departamento de Estatística pela estrutura e formação oferecidas ao longo do curso.

Referências

- BORGOMEIO, Letizia; KOENIG, Christoph; MIOTTO, Martina. The long-run effects of R&D subsidies on high-tech start-ups: insights from Italy. *Economics Letters*, v. 248, 112154, 2025. DOI: 10.1016/j.econlet.2024.112154.
- GOMES, Leonardo Augusto de Vasconcelos; SALERNO, Mario Sergio; PHAAL, Robert; PROBERT, David R. How entrepreneurs manage collective uncertainties in innovation ecosystems. *Technological Forecasting and Social Change*, v. 128, p. 164–185, 2018.
- DELMAR, Frédéric; MCKELVIE, Alexander; WENNBORG, Karl. Untangling the relationships among growth, profitability and survival in new firms. *Technovation*, v. 33, n. 8–9, p. 276–291, 2013.
- BREIMAN, Leo. Random forests. *Machine Learning*, v. 45, n. 1, p. 5–32, 2001.
- BREUSCH, Trevor S.; PAGAN, Adrian R. A simple test for heteroscedasticity and random coefficient variation. *Econometrica*, v. 47, n. 5, p. 1287–1294, 1979.
- CHEN, Tianqi; GUESTRIN, Carlos. XGBoost: a scalable tree boosting system. In: *PROCEEDINGS OF THE 22ND ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING*. Nova Iorque: ACM, 2016. p. 785–794.
- COOK, R. Dennis. Detection of influential observation in linear regression. *Technometrics*, v. 19, n. 1, p. 15–18, 1977.
- CORTES, Corinna; VAPNIK, Vladimir. Support-vector networks. *Machine Learning*, v. 20, n. 3, p. 273–297, 1995.
- JAMES, Gareth; WITTEN, Daniela; HASTIE, Trevor; TIBSHIRANI, Robert. *An introduction to statistical learning: with applications in R*. Nova Iorque: Springer, 2013.
- JOGLEKAR, Nitin R.; LEVESQUE, Moren. Marketing, R&D, and startup valuation. *IEEE Transactions on Engineering Management*, v. 56, n. 2, p. 229–242, 2009.
- SHAPIRO, Samuel S.; WILK, Martin B. An analysis of variance test for normality (complete samples). *Biometrika*, v. 52, n. 3-4, p. 591–611, 1965.
- TAYLOR, Karl E. Summarizing multiple aspects of model performance in a single diagram. *Journal of Geophysical Research: Atmospheres*, v. 106, n. D7, p. 7183–7192, 2001.
- WILLMOTT, Cort J. On the validation of models. *Physical Geography*, v. 2, n. 2, p. 184–194, 1981.