

ANÁLISE DE REGRESSÃO

PREDIÇÃO DE LUCRO DE STARTUPS: UMA AVALIAÇÃO COMPARATIVA ENTRE REGRESSÃO LINEAR MÚLTIPLA E MODELOS DE APRENDIZAGEM DE MÁQUINA

Vanessa Cavalcante
Universidade Estadual da Paraíba — CCT
Departamento de Estatística
Professor: Romário de Souza Almeida
Campina Grande — PB • 2026

DESTAQUES DO ARTIGO

Os quatro achados que orientam toda a apresentação

1 • REGRESSÃO LINEAR VENCEU

A regressão linear múltipla apresentou o menor RMSE no conjunto de teste: 6.324,63.

2 • P&D É DOMINANTE

R.D.Spend foi a variável de maior poder explicativo em todos os modelos avaliados.

3 • DIAGNÓSTICOS IMPORTAM

Cook, leverage e resíduos estudentizados identificaram quatro observações influentes.

4 • LINEARIDADE FOI SUFICIENTE

A pequena amostra e a relação predominantemente linear favoreceram um modelo parcimonioso.

1- INTRODUÇÃO

Contexto e problema de pesquisa

- Startups operam sob elevada incerteza e precisam alocar recursos entre P&D, Marketing e Administração.
- O investimento em P&D é apontado na literatura como importante preditor de valor de mercado e lucratividade futura.
- Modelos de aprendizado de máquina capturam não linearidades e interações, mas podem apresentar maior variância em amostras pequenas.
- O artigo pergunta se a flexibilidade dos algoritmos supera, nesta base, a regressão linear múltipla.

IDEIA CENTRAL

A comparação é feita em igualdade de condições: mesma divisão treino–teste e métricas comuns, mas com diagnóstico estatístico completo para a regressão.

OBJETIVOS

OBJETIVO GERAL

Desenvolver e comparar o desempenho preditivo da regressão linear múltipla e de modelos de aprendizado de máquina na predição do lucro.

OBJETIVOS ESPECÍFICOS

- Caracterizar estatisticamente a base.
- Ajustar e diagnosticar a regressão.
- Calibrar RF, XGBoost e SVM.
- Comparar as previsões por várias métricas.
- Identificar a importância das variáveis.
- Discutir os resultados à luz de Joglekar e Levesque (2009).

2- METODOLOGIA

Desenho geral do estudo

BASE

50 startups dos EUA, localizadas em Califórnia, Flórida e Nova Iorque.

DIVISÃO

80% treino e 20% teste. A calibração usa validação cruzada repetida: 10 folds × 3 repetições.

MODELOS

Regressão Linear Múltipla, Random Forest, XGBoost e SVM.

VARIÁVEIS

R.D.Spend, Administration, Marketing.Spend, State (dummies) → Profit. O conjunto de teste não participa do treinamento nem da calibração.

SOFTWARE

Todas as análises, modelos, tabelas e gráficos foram realizados em R, por meio do RStudio.

ÁREA DE ESTUDO E COLETA

ÁREA DE ESTUDO

Base “50 Startups”, utilizada como referência didática e empírica em regressão múltipla aplicada a finanças corporativas.

ESTADOS

Califórnia, Flórida e Nova Iorque — tratados como categorias de uma variável qualitativa.

VARIÁVEL RESPOSTA E PREDITORES

Profit = lucro anual. Preditores: R.D.Spend, Administration, Marketing.Spend e State.

TABELA 1 — ESTATÍSTICA DESCRITIVA

n = 50 startups


Variável	Média	Desvio-padrão	Mediana	Mínimo	Máximo	Assimetria	Curtose
R.D.Spend	73.721,62	45.902,26	73.051,08	0,00	165.349,20	0,154	-0,892
Administration	121.344,64	28.017,80	122.699,80	51.283,14	182.645,56	-0,460	-0,037
Marketing.Spend	211.025,10	122.290,31	212.716,24	0,00	471.784,10	-0,044	-0,814

LEITURA DA TABELA

R.D.Spend apresenta a maior dispersão relativa ($CV \approx 62\%$). Administration é a mais homogênea. As assimetrias não são acentuadas, o que sustenta a ausência de transformação logarítmica obrigatória.

FIGURA 1 — DISTRIBUIÇÃO DE FREQUÊNCIAS

Figura 1 do artigo • resultados na mesma sequência do texto



INTERPRETAÇÃO

R.D.Spend reúne startups com investimento nulo/baixo e outro agrupamento entre 60 e 100 mil dólares. Marketing.Spend tem pico entre 250 e 300 mil. Profit concentra-se entre 90 e 160 mil, com cauda superior.

MODELO DE REGRESSÃO LINEAR MÚLTIPLA

Equação 1 • Mínimos Quadrados Ordinários

$$\text{Profit}_i = \beta_0 + \beta_1 \text{R.D.Spend}_i + \beta_2 \text{Administration}_i + \beta_3 \text{Marketing.Spend}_i + \beta_4 \text{State}_i + \varepsilon_i$$

$\varepsilon_i \sim N(0, \sigma^2)$; State é representada por variáveis dummy, com Califórnia como categoria de referência.

β_0

Intercepto: lucro esperado quando os preditores numéricos são zero, na categoria de referência.

β_1

Efeito marginal de R.D.Spend, mantendo as demais variáveis constantes.

β_2, β_3

Efeitos marginais de Administração e Marketing.

ε_i

Erro aleatório que reúne fatores não explicados pelo modelo.

No caso de State, Flórida e Nova Iorque são comparadas à Califórnia.

DIAGNÓSTICO DA REGRESSÃO

Pressupostos avaliados antes da comparação

MULTICOLINEARIDADE

GVIF, com referência $GVIF^{(1/(2 \cdot Df))} < 2$.

HOMOCEDASTICIDADE

Teste de Breusch–Pagan: H_0 = variância constante.

NORMALIDADE

Teste de Shapiro–Wilk + QQ-plot dos resíduos.

INFLUÊNCIA

Distância de Cook, leverage, RStudent e DFBETAS.

POR QUE ISSO IMPORTA

O modelo linear não foi tratado como um baseline ingênuo. A adequação foi investigada antes de comparar seu desempenho com Machine Learning.

RANDOM FOREST — FORMULAÇÃO

$$\hat{y}_i = \frac{1}{B} \sum_{b=1}^B T^b(x_i)$$

A previsão final é a média das previsões das B árvores do ensemble.

- Cada árvore é treinada sobre uma amostra bootstrap dos dados.
- Em cada divisão, um subconjunto aleatório de preditores é considerado.
- Hiperparâmetros: mtry, regra de divisão (variance ou extratrees) e tamanho mínimo do nó terminal.

XGBOOST — FORMULAÇÃO

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i), \quad f_k \in \mathcal{F}$$

O modelo é uma soma de K árvores, construídas sequencialmente.

$$\mathcal{L}(\phi) = \sum_i l(y_i, \hat{y}_i) + \sum_k \Omega(f_k), \quad \Omega(f) = \gamma T + \frac{1}{2} \lambda \|w\|^2$$

A função objetivo combina perda preditiva e regularização da complexidade das árvores.

γ e λ controlam a penalização; T representa o número de folhas e w os pesos das folhas.

SUPPORT VECTOR MACHINE — FORMULAÇÃO

$$f(x) = \sum_{i=1}^n (\alpha_i - \alpha_i^*) K(x_i, x) + b$$

A previsão usa multiplicadores de Lagrange e um kernel radial.

$$K(\mathbf{X}_i, \mathbf{X}_j) = \exp(-\gamma \|\mathbf{X}_i - \mathbf{X}_j\|^2)$$

COST

Controla a penalização por erros fora da margem ε .

SIGMA

Controla a largura do kernel radial e, portanto, a flexibilidade não linear.

MÉTRICAS DE AVALIAÇÃO — ERROS

Quanto menor, melhor

Erro absoluto médio; mede o tamanho médio dos erros sem elevar ao quadrado.

$$MAD = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Viés médio; próximo de zero indica pouco viés sistemático.

$$MBE = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)$$

Penaliza fortemente erros grandes.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Retorna o erro à mesma unidade de Profit; é a principal métrica do ranking.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2}$$

MÉTRICAS DE AVALIAÇÃO — PERCENTUAL E AJUSTE

Complementos

Erro percentual absoluto médio.

$$\text{MAPE} = \frac{100}{n} \sum_{i=1}^n \left| \frac{Y_i - \hat{Y}_i}{Y_i} \right|$$

Proporção da variabilidade observada explicada pelo modelo; maior é melhor.

$$R^2 = 1 - \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}$$

Eficiência de Nash–Sutcliffe; valores próximos de 1 indicam alta eficiência.

$$\text{NSE} = 1 - \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}$$

Concordância de Lin; combina correlação, escala e viés.

$$\text{CCC} = \frac{2\rho\sigma_Y\sigma_{\hat{Y}}}{\sigma_Y^2 + \sigma_{\hat{Y}}^2 + (\mu_Y - \mu_{\hat{Y}})^2}$$

MÉTRICAS DE AVALIAÇÃO — CONCORDÂNCIA E VIÉS

Complementos

Viés percentual: positivo = tendência de superestimação; negativo = subestimação.

$$\text{PBIAS} = 100 \frac{\sum_{i=1}^n (\mathbf{Y}_i - \hat{\mathbf{Y}}_i)}{\sum_{i=1}^n \mathbf{Y}_i}$$

Razão de desempenho de predição; valores maiores indicam melhor desempenho relativo.

$$\text{RPD} = \frac{\text{SD}}{\text{RMSE}}$$

RMSE relativo à média observada.

$$\text{RPD} = \frac{\text{SD}}{\text{RMSE}}$$

O artigo também usa Correlação de Pearson, Bias absoluto, Willmott e TaylorSkill; o IC 95% do RMSE é obtido por bootstrap não paramétrico.

3- RESULTADO E DISCUSSÃO

TABELA 2 — MULTICOLINEARIDADE

GVIF

Variável	GVIF	Df	$GVIF^{(1/(2 \cdot Df))}$
R.D.Spend	2,496	1	1,580
Administration	1,178	1	1,085
Marketing.Spend	2,417	1	1,555
State	1,063	2	1,015

CONCLUSÃO

Todos os valores ajustados ficaram abaixo de 2. Portanto, não há evidência de multicolinearidade preocupante entre os preditores.

TABELA 3 — COEFICIENTES ESTIMADOS

Modelo de regressão linear múltipla saturado


Termo	Estimativa	Erro-padrão	Estatística t	Valor-p
Intercepto	50.125,34	6.884,82	7,281	< 0,001
R.D.Spend	0,806	0,046	17,369	< 0,001
Administration	-0,027	0,052	-0,517	0,608
Marketing.Spend	0,027	0,017	1,574	0,123
State (Flórida)	198,79	3.371,01	0,059	0,953
State (Nova Iorque)	-41,89	3.256,04	-0,013	0,990

LEITURA

R.D.Spend é o único preditor significativo a 5%. Seu coeficiente 0,806 indica que, mantendo os demais fatores constantes, US\$ 1 adicional em P&D está associado a aproximadamente US\$ 0,81 de lucro adicional.

FIGURA 2 — PAINEL DE DIAGNÓSTICOS

Figura 2 do artigo • resultados na mesma sequência do texto




INTERPRETAÇÃO

Resíduos versus valores ajustados não mostram curvatura sistemática.
O QQ-plot acompanha bem a normalidade no centro, com afastamentos nas caudas. O painel de leverage destaca observações potencialmente influentes.

FIGURA 3 — DISTÂNCIA DE COOK

Figura 3 do artigo • resultados na mesma sequência do texto




INTERPRETAÇÃO

A linha de referência é $4/n = 0,08$. As observações #46, #47, #49 e #50 ultrapassam o limiar e devem ser investigadas.

FIGURA 4 — ALAVANCAGEM

Figura 4 do artigo • resultados na mesma sequência do texto




INTERPRETAÇÃO

A referência é $2p/n = 0,24$. As observações #47 e #49 apresentam os maiores valores de leverage, sinalizando combinações incomuns de preditores.

FIGURA 5 — QQ-PLOT DOS RESÍDUOS ESTUDENTIZADOS

Figura 5 do artigo • resultados na mesma sequência do texto




INTERPRETAÇÃO

As observações #46, #49 e #50 se afastam mais da normalidade teórica nas caudas. A maior parte dos pontos acompanha a reta.

FIGURA 6 — RESÍDUOS ESTUDENTIZADOS

Figura 6 do artigo • resultados na mesma sequência do texto




INTERPRETAÇÃO

A linha de corte em -3 identifica a observação #50 como o caso claramente mais extremo.

FIGURA 7 — RESÍDUOS VERSUS VALORES PREDITOS

Figura 7 do artigo • resultados na mesma sequência do texto



INTERPRETAÇÃO

Os diagnósticos indicam que o modelo de regressão linear múltipla é globalmente adequado, com a ressalva de quatro observações influentes que, embora não invalidem as conclusões substantivas do modelo (o coeficiente de R.D.Spend permanece o único preditor robustamente significativo mesmo após sua remoção, conforme análise de sensibilidade), elevam a variância dos coeficientes estimados e devem ser reportadas com transparência — prática nem sempre observada em estudos que comparam regressão linear a modelos de aprendizado de máquina sem submeter o primeiro ao mesmo escrutínio dedicado aos segundos.

OBSERVAÇÕES INFLUENTES

Síntese dos diagnósticos


Obs.	Cook	Leverage	RStudent	DFFITS
46	0,0944	0,1277	2,036	0,779
47	0,0423	0,2654	-0,835	-0,502
49	0,1564	0,2559	-1,686	-0,989
50	0,2640	0,1015	-4,485	-1,507

DESTAQUE

#50 é a mais influente: RStudent = -4,485 e Cook = 0,2640. Quatro observações devem ser reportadas, mas sua presença não altera a conclusão central sobre R.D.Spend.

FIGURA 8 — CALIBRAÇÃO DO RANDOM FOREST

Figura 8 do artigo • resultados na mesma sequência do texto




INTERPRETAÇÃO

O RMSE de validação cruzada diminui com o aumento de mtry. A regra variance com tamanho mínimo do nó igual a 1 produz o menor erro, próximo de 10.600.

FIGURA 9 — IMPORTÂNCIA DAS VARIÁVEIS NO RANDOM FOREST

Figura 9 do artigo • resultados na mesma sequência do texto




INTERPRETAÇÃO

R.D.Spend domina a importância relativa (~1,89×10⁹). Marketing fica muito atrás (~2,96×10⁸). Administração e State têm importância residual.

FIGURA 10 — OBSERVADO × PREDITO: RANDOM FOREST

Figura 10 do artigo • resultados na mesma sequência do texto




INTERPRETAÇÃO

Há boa aderência geral à reta de identidade, mas o modelo tende a subestimar os lucros nos extremos superiores.

FIGURA 11 — RESÍDUOS: RANDOM FOREST

Figura 11 do artigo • resultados na mesma sequência do texto




INTERPRETAÇÃO

Os maiores resíduos absolutos concentram-se nas observações de maior lucro predito, refletindo a dificuldade dos ensembles de árvores em extrapolar.

FIGURA 12 — IMPORTÂNCIA DAS VARIÁVEIS NO XGBOOST

Figura 12 do artigo • resultados na mesma sequência do texto




INTERPRETAÇÃO

R.D.Spend responde por 94,5% do ganho total; Marketing por 5,2%; Administração por 0,3% e a dummy de Nova Iorque por 0,08%.

FIGURA 13 — OBSERVADO × PREDITO: XGBOOST

Figura 13 do artigo • resultados na mesma sequência do texto




INTERPRETAÇÃO

A aderência à reta de identidade é inferior à dos outros modelos, coerente com o maior RMSE.

FIGURA 14 — RESÍDUOS: XGBOOST

Figura 14 do artigo • resultados na mesma sequência do texto




INTERPRETAÇÃO

É o modelo com maior dispersão de resíduos; os erros chegam a superar US\$ 30 mil em módulo. O artigo relaciona esse comportamento ao sobreajuste em amostra pequena.

FIGURA 15 — CALIBRAÇÃO DO SVM

Figura 15 do artigo • resultados na mesma sequência do texto




INTERPRETAÇÃO

O RMSE cai rapidamente com o aumento do Cost e estabiliza aproximadamente entre 10.000 e 12.000. Os melhores resultados ocorrem com Sigma intermediário e Cost elevado.

FIGURA 16 — OBSERVADO × PREDITO: SVM

Figura 16 do artigo • resultados na mesma sequência do texto




INTERPRETAÇÃO

O SVM apresenta aderência intermediária e não mostra o mesmo padrão de subestimação extrema nos maiores lucros observado no Random Forest.

FIGURA 17 — RESÍDUOS: SVM

Figura 17 do artigo • resultados na mesma sequência do texto



INTERPRETAÇÃO

Os resíduos são intermediários entre Random Forest e XGBoost, com dispersão relevante, mas sem o padrão de achatamento dos modelos de árvores.

TABELA 5 — DESEMPENHO PREDITIVO

Conjunto de teste


Modelo	RMSE	MAE	R ²	MAPE (%)	NSE	CCC	PBIAS (%)
Regressão Linear	6.324,63	5.657,44	0,988	6,13	0,980	0,990	3,06
Random Forest	10.547,37	8.577,79	0,960	10,56	0,945	0,970	4,42
SVM	11.874,48	10.301,53	0,974	13,32	0,930	0,960	6,69
XGBoost	17.689,17	14.260,08	0,898	18,07	0,845	0,916	-9,28

VENCEDOR

Regressão Linear: menor RMSE, MAE e MAPE; maior R², NSE e CCC. O SVM supera o Random Forest em R², mas apresenta RMSE maior — mostrando por que várias métricas devem ser usadas.

FIGURA 18 — RANKING PELO RMSE

Figura 18 do artigo • resultados na mesma sequência do texto




INTERPRETAÇÃO

Menor RMSE = melhor. A regressão linear aparece em primeiro, seguida por Random Forest, SVM e XGBoost.

FIGURA 19 — COEFICIENTE DE DETERMINAÇÃO (R²)

Figura 19 do artigo • resultados na mesma sequência do texto



INTERPRETAÇÃO

Regressão Linear = 0,988; SVM = 0,974; Random Forest = 0,960; XGBoost = 0,898. SVM supera RF nesta métrica específica.

TABELA 6 — IC 95% DO RMSE

Bootstrap não paramétrico


Modelo	RMSE	IC 95% inferior	IC 95% superior
Regressão Linear	6.324,63	4.479,02	7.877,72
Random Forest	10.547,37	5.678,27	14.612,72
SVM	11.874,48	7.129,83	15.740,53
XGBoost	17.689,17	9.466,75	24.647,16

O QUE O IC MOSTRA

O intervalo da regressão linear é muito inferior aos de SVM e XGBoost e, em grande parte, inferior ao de Random Forest. A diferença não é apenas pontual.

FIGURA 20 — RADAR DE DESEMPENHO

Figura 20 do artigo • resultados na mesma sequência do texto




INTERPRETAÇÃO

A regressão linear domina visualmente as demais em praticamente todas as métricas normalizadas: RMSE, TaylorSkill, CCC, NSE, R^2 e MAE.

FIGURA 21 — OBSERVADO × PREDITO: COMPARAÇÃO

Figura 21 do artigo • resultados na mesma sequência do texto




INTERPRETAÇÃO

A regressão linear é a mais próxima da reta de identidade. XGBoost apresenta os maiores afastamentos.

FIGURA 22 — RESÍDUOS POR MODELO

Figura 22 do artigo • resultados na mesma sequência do texto




INTERPRETAÇÃO

O painel mostra menor dispersão geral para a regressão linear e maior dispersão para XGBoost.

FIGURA 23 — IMPORTÂNCIA: RANDOM FOREST × XGBOOST

Figura 23 do artigo • resultados na mesma sequência do texto




INTERPRETAÇÃO

Os dois algoritmos convergem para a mesma conclusão: R.D.Spend é, de longe, a variável mais importante.

FIGURA 24 — DIAGRAMA DE TAYLOR

Figura 24 do artigo • resultados na mesma sequência do texto



INTERPRETAÇÃO

O ponto ideal combina correlação 1 e desvio-padrão igual ao observado. A regressão linear é a mais próxima do ponto ideal, seguida por SVM, Random Forest e XGBoost.

INTERPRETAÇÃO CONJUNTA

Resultados à luz do artigo

P&D É ROBUSTO

R.D.Spend foi dominante na regressão, Random Forest e XGBoost — e continua central no SVM.

Amostra PEQUENA

$n = 50$; apenas 42 observações de treinamento. Maior flexibilidade pode elevar a variância.

LINEARIDADE

Se a relação for suave e monotônica, o modelo linear pode capturar a estrutura sem pagar o custo da complexidade.

NO FREE LUNCH

O resultado não diz que Machine Learning é inferior em geral. A superioridade de um algoritmo depende das características do conjunto de dados, da amostra e da forma da relação entre variáveis.

JOGLEKAR E LEVESQUE (2009)

- Joglekar e Levesque relacionam investimento em P&D, Marketing e valoração de startups.
- Em estágios iniciais, quando a incerteza tecnológica domina, o retorno marginal de P&D tende a superar o de Marketing.
- Neste artigo, P&D foi o único preditor estatisticamente significativo na regressão e respondeu por mais de 90% da importância relativa nos modelos de árvores.
- A superioridade da regressão linear é compatível com uma relação aproximadamente monotônica e suave dentro do intervalo observado.
- Em amostras maiores ou com não linearidades/interações mais fortes, modelos flexíveis podem superar a regressão.

4- CONCLUSÃO

- A Regressão Linear Múltipla apresentou o melhor desempenho preditivo: RMSE = 6.324,63.
- Random Forest foi o segundo melhor modelo; SVM e XGBoost apresentaram erros maiores.
- R.D.Spend foi o determinante mais relevante do lucro em todas as arquiteturas avaliadas.
- Os diagnósticos identificaram quatro observações influentes, sem alterar a conclusão substantiva central.
- A pequena dimensão amostral é uma limitação importante para generalização.
- Pesquisas futuras devem utilizar bases maiores e incluir variáveis como setor, estágio de financiamento e idade da empresa.

RESULTADO CENTRAL

Nesta aplicação específica, a simplicidade da regressão linear foi uma vantagem: menor erro, maior concordância e interpretação estatística direta.

AGRADECIMENTOS

Agradeço ao professor Romário de Souza Almeida pela orientação, disponibilidade e pelos ensinamentos transmitidos ao longo da disciplina de Análise de Regressão.

REFERÊNCIAS

- BREIMAN, L. Random forests. *Machine Learning*, 45, 5–32, 2001.
- BREUSCH, T. S.; PAGAN, A. R. A simple test for heteroscedasticity. *Econometrica*, 47, 1287–1294, 1979.
- CHEN, T.; GUESTRIN, C. XGBoost: a scalable tree boosting system. *ACM SIGKDD*, 2016.
- COOK, R. D. Detection of influential observation in linear regression. *Technometrics*, 19, 15–18, 1977.
- CORTES, C.; VAPNIK, V. Support-vector networks. *Machine Learning*, 20, 273–297, 1995.
- JAMES, G.; WITTEN, D.; HASTIE, T.; TIBSHIRANI, R. *An Introduction to Statistical Learning*. Springer, 2013.
- JOGLEKAR, N. R.; LEVESQUE, M. Marketing, R&D, and startup valuation. *IEEE TEM*, 56, 229–242, 2009.
- SHAPIRO, S. S.; WILK, M. B. An analysis of variance test for normality. *Biometrika*, 52, 591–611, 1965.
- TAYLOR, K. E. Summarizing multiple aspects of model performance in a single diagram. *JGR*, 106, 7183–7192, 2001.
- WILLMOTT, C. J. On the validation of models. *Physical Geography*, 2, 184–194, 1981.
- BORGOMEIO, L.; KOENIG, C.; MIOTTO, M. The long-run effects of R&D subsidies on high-tech start-ups. *Economics Letters*, 248, 112154, 2025.
- GOMES, L. A. V. et al. How entrepreneurs manage collective uncertainties in innovation ecosystems. *Technological Forecasting and Social Change*, 128, 164–185, 2018.
- DELMAR, F.; MCKELVIE, A.; WENNBERG, K. Untangling the relationships among growth, profitability and survival in new firms. *Technovation*, 33, 276–291, 2013.

MUITO OBRIGADA!

Vanessa Cavalcante
Análise de Regressão • UEPB • 2026
Professor: Romário de Souza Almeida